

Checkpoint 2 - Análise Exploratória Dataset Iris

Diagnóstico para Modelagem com kNN

Vinicius Felix Vitor Vitorino Arthur Lins
Silvio Neto Thaina Santos

2026-04-16

Índice

1	Introdução	2
2	Configuração do Ambiente	2
3	Análise Exploratória de Dados	3
3.1	Primeiras Impressões	3
4	Limpeza e Qualidade dos Dados	4
5	Estatística Descritiva	5
5.1	Média	5
5.2	Mediana	5
5.3	Desvio Padrão	6
5.4	Medidas de Amplitude	7
5.4.1	Mínimo	7
5.4.2	Máximo	7
6	Visualizando Outliers	8
7	Conclusão	9

1 Introdução



Figura 1: Iris virginica, versicolor e setosa.

“Se quisermos aprender algo sobre a natureza última das espécies, devemos reduzir o problema aos termos mais simples e estudar algumas espécies facilmente reconhecidas e bem diferenciadas” - Edgar Anderson

O conjunto de dados Iris é muito mais do que apenas um exercício para iniciantes, é a “cápsula do tempo” que uniu a estatística clássica de 1936 com a era moderna do Aprendizado de Máquina. Criado por Ronald Fisher em uma época de cálculos manuais, ele ganhou nova vida na década de 1980 como membro fundador do Repositório UCI, tornando-se a primeira régua universal para comparar algoritmos quando o poder computacional ainda era um luxo.

Com apenas 150 amostras, ele sobreviveu às décadas ao ocupar um “ponto ideal” raro: é simples o suficiente para não intimidar, mas possui uma sobreposição sutil entre as espécies que pune o descuido. Para o k-Vizinhos Mais Próximos (kNN), o Iris é o mentor que força o cientista de dados a perceber que a distância matemática entre os pontos é o que define a realidade.

2 Configuração do Ambiente

Este projeto utiliza o `renv` para reprodutibilidade. Para restaurar as versões exatas dos pacotes, execute este comando no seu console do R após clonar este repositório:

```
renv::restore()
```

- The library is already synchronized with the lockfile.

Utilizaremos três pacotes principais:

`tidyverse`, para manipulação de dados

`Gally`, para gráficos de correlação/pares que mostram as 4 variáveis simultaneamente

`knitr`, para formatar tabelas de forma elegante no HTML gerado

```
library(tidyverse)
library(GGally)
library(knitr)
```

3 Análise Exploratória de Dados

3.1 Primeiras Impressões

Vamos verificar a diferença entre estas duas funções populares para iniciar uma análise de dados.

```
glimpse(iris)
```

```
Rows: 150
Columns: 5
$ Sepal.Length <dbl> 5.1, 4.9, 4.7, 4.6, 5.0, 5.4, 4.6, 5.0, 4.4, 4.9, 5.4, 4.~
$ Sepal.Width <dbl> 3.5, 3.0, 3.2, 3.1, 3.6, 3.9, 3.4, 3.4, 2.9, 3.1, 3.7, 3.~
$ Petal.Length <dbl> 1.4, 1.4, 1.3, 1.5, 1.4, 1.7, 1.4, 1.5, 1.4, 1.5, 1.5, 1.~
$ Petal.Width <dbl> 0.2, 0.2, 0.2, 0.2, 0.2, 0.4, 0.3, 0.2, 0.2, 0.1, 0.2, 0.~
$ Species <fct> setosa, setosa, setosa, setosa, setosa, setosa, setosa, s~
```

Como podemos observar, o `glimpse()` fornece uma visão bem formatada e organizada para conjuntos de dados, exibida de forma horizontal, incluindo:

Número de Linhas

Número de Colunas

Nomes das colunas

Tipo de dado de cada coluna

`dbl` - double, valores numéricos decimais

`fct` - factor, variável categórica com níveis definidos

Como podemos ver, ele é projetado para mostrar a estrutura, não todos os valores, portanto não é a ferramenta ideal para visualizar todos os valores únicos.

Vamos conferir como o `summary()` difere da função anterior.

```
summary(iris)
```

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min. :4.300	Min. :2.000	Min. :1.000	Min. :0.100
1st Qu.:5.100	1st Qu.:2.800	1st Qu.:1.600	1st Qu.:0.300
Median :5.800	Median :3.000	Median :4.350	Median :1.300
Mean :5.843	Mean :3.057	Mean :3.758	Mean :1.199
3rd Qu.:6.400	3rd Qu.:3.300	3rd Qu.:5.100	3rd Qu.:1.800
Max. :7.900	Max. :4.400	Max. :6.900	Max. :2.500

```

      Species
setosa      :50
versicolor:50
virginica   :50

```

Ele fornece uma visão geral estatística rápida de um determinado conjunto de dados ou vetor. Quando aplicado a dados numéricos, retorna as seguintes estatísticas resumidas principais:

Min: 0 valor mínimo nos dados

1st Qu: 0 primeiro quartil (percentil 25)

Median: 0 valor central (percentil 50)

3rd Qu: 0 terceiro quartil (percentil 75)

Max: 0 valor máximo nos dados

4 Limpeza e Qualidade dos Dados

A limpeza vem antes da estatística; ao tratar as inconsistências primeiro, garantimos que a média, variância e desvio padrão calculados reflitam fielmente a verdadeira natureza da população.

Vamos começar verificando na/NaN em nossos dados. Se os encontrarmos, eles podem ter dois significados: dados ausentes ou não aplicável.

Se forem Dados Ausentes: Geralmente você faz a imputação (preenche com a média/mediana) ou remove a linha se a perda for mínima.

Se for Não Aplicável: Frequentemente você faz a codificação (ex: substitui NaN por 0 ou uma categoria como “Nenhum”) para que o modelo entenda que a ausência é uma informação em si.

```
colSums(is.na(iris))
```

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	0	0	0	0

5 Estatística Descritiva

5.1 Média

O objetivo principal da estatística descritiva é resumir e organizar as características de um conjunto de dados para que ele seja fácil de entender. Em vez de olhar para 150 linhas de dados brutos, estas métricas oferecem um “panorama” dos valores típicos e da diversidade dentro dos dados.

Utilizando o Dataset Iris, vamos detalhar estes conceitos fundamentais.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

```
iris %>%
  group_by(Species) %>%
  summarise(
    mean_sepal_length = mean(Sepal.Length),
    mean_sepal_width = mean(Sepal.Width),
    mean_petal_length = mean(Petal.Length),
    mean_petal_width = mean(Petal.Width)
  ) %>%
  kable()
```

Species	mean_sepal_length	mean_sepal_width	mean_petal_length	mean_petal_width
setosa	5.006	3.428	1.462	0.246
versicolor	5.936	2.770	4.260	1.326
virginica	6.588	2.974	5.552	2.026

A análise mostra que o Petal.Length da setosa possui uma grande lacuna em relação às outras espécies, e o Isolamento trabalha a favor da classificação.

5.2 Mediana

Se você enfileirar todas as 150 flores, da sépala mais curta para a mais longa, a mediana é o valor exatamente no meio (os valores 75 e 76).

Por que isso importa: Ao contrário da média, a mediana não é “puxada” por valores extremos (como uma única flor gigante de 20 cm). Se a média e a mediana estiverem próximas, é provável que seus dados sejam simétricos.

```
iris %>%
  group_by(Species) %>%
  summarise(
```

```

median_sepal_length = median(Sepal.Length),
median_sepal_width = median(Sepal.Width),
median_petal_length = median(Petal.Length),
median_petal_width = median(Petal.Width)
) %>%
  kable()

```

Species	median_sepal_length	median_sepal_width	median_petal_length	median_petal_width
setosa	5.0	3.4	1.50	0.2
versicolor	5.9	2.8	4.35	1.3
virginica	6.5	3.0	5.55	2.0

Os valores da média e da mediana estão próximos para todas as espécies, sugerindo que o conjunto de dados Iris possui distribuições normais.

5.3 Desvio Padrão

Mede o quão longe cada número no conjunto está da média. Matematicamente, é a média das diferenças quadradas em relação à Média.

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

```

iris %>%
  group_by(Species) %>%
  summarise(
    sd_sepal_length = sd(Sepal.Length),
    sd_sepal_width = sd(Sepal.Width),
    sd_petal_length = sd(Petal.Length),
    sd_petal_width = sd(Petal.Width)
  ) %>%
  kable()

```

Species	sd_sepal_length	sd_sepal_width	sd_petal_length	sd_petal_width
setosa	0.3524897	0.3790644	0.1736640	0.1053856
versicolor	0.5161711	0.3137983	0.4699110	0.1977527
virginica	0.6358796	0.3224966	0.5518947	0.2746501

5.4 Medidas de Amplitude

5.4.1 Mínimo

O menor valor registrado.

```
iris %>%
  group_by(Species) %>%
  summarise(
    min_sepal_length = min(Sepal.Length),
    min_sepal_width = min(Sepal.Width),
    min_petal_length = min(Petal.Length),
    min_petal_width = min(Petal.Width)
  ) %>%
  kable()
```

Species	min_sepal_length	min_sepal_width	min_petal_length	min_petal_width
setosa	4.3	2.3	1.0	0.1
versicolor	4.9	2.0	3.0	1.0
virginica	4.9	2.2	4.5	1.4

5.4.2 Máximo

O maior valor registrado.

```
iris %>%
  group_by(Species) %>%
  summarise(
    max_sepal_length = max(Sepal.Length),
    max_sepal_width = max(Sepal.Width),
    max_petal_length = max(Petal.Length),
    max_petal_width = max(Petal.Width)
  ) %>%
  kable()
```

Species	max_sepal_length	max_sepal_width	max_petal_length	max_petal_width
setosa	5.8	4.4	1.9	0.6
versicolor	7.0	3.4	5.1	1.8
virginica	7.9	3.8	6.9	2.5


Existe uma lacuna de 1,1 cm — significando que nenhuma flor setosa tem comprimento de pétala acima de 1,9, e nenhuma flor versicolor tem comprimento de pétala abaixo de 3,0.

6 Visualizando Outliers

Como o k-Vizinhos Mais Próximos (kNN) é um algoritmo baseado em distância, os outliers podem distorcer significativamente as fronteiras de classificação. Um único valor extremo pode “puxar” o cálculo do vizinho mais próximo para a classe errada.

Utilizaremos Boxplots para visualizar a distribuição e identificar quaisquer pontos que estejam fora do intervalo interquartil (IQR).

```
iris %>%
  pivot_longer(
    cols = -Species,
    names_to = "Feature",
    values_to = "Value"
  ) %>%
  ggplot(aes(x = Species, y = Value, fill = Species)) +
  geom_boxplot(outlier.colour = "red", outlier.shape = 16) +
  facet_wrap(~Feature, scales = "free_y") +
  theme_minimal() +
  labs(
    title = "Detecção de Outliers por Espécie",
    x = "Espécie",
    y = "Medida (cm)"
  )
)
```



Portanto, estes outliers não devem ser removidos antes do treinamento do KNN porque representam variações biológicas naturais, embora raras, de uma espécie

altamente consistente, e removê-los simplificaria artificialmente a compreensão do modelo sobre a complexidade real dos dados.

7 Conclusão

A análise exploratória demonstra que o dataset Iris possui características ideais para o algoritmo kNN, mas exige atenção à estrutura das suas variáveis. A espécie Setosa apresenta uma separabilidade clara, garantindo alta precisão devido à sua distância em relação às demais. Já a sobreposição entre Versicolor e Virginica torna o modelo dependente de um ajuste rigoroso do hiperparâmetro k , uma vez que a fronteira de decisão será definida pela densidade local de pontos onde as médias das espécies se aproximam.

Para assegurar a eficácia do modelo, é necessária a aplicação de normalização (escala) nas features, garantindo que variáveis de maior magnitude não distorçam os cálculos de proximidade. Embora a baixa variância observada favoreça a consistência do kNN, a presença de outliers na largura da sépala reforça a necessidade de um modelo robusto, capaz de ignorar ruídos pontuais para manter uma boa generalização sobre a complexidade biológica real dos dados.